

# Notes for Log-Concave Polynomials II

Xiaoyu Chen

## 1 背景知识

这篇文章中涉及了大量我以往不太了解的技术, 这里集中做一个整理. 为了节约时间, 我会略过所有我能马上反应过来的推导. 并且, 为了简化工作, 尽量省略了所有的交叉引用, 如果发现后面有地方的证明看不过去, 可以去翻前面的结论.

### 1.1 线性代数

#### 1.1.1 Schur Product Theorem

**Fact 1.**  $\text{tr}(AB^T) = \sum_{i,j=1}^n A_{ij}B_{ij}$

*proof.*  $\text{tr}(AB^T) = \sum_i (AB^T)_{ii} = \sum_{i=1}^n \sum_{j=1}^n A_{ij}B_{ji}^T = \sum_{i,j=1}^n A_{ij}B_{ij}$  □

**Fact 2.**  $x^*(A \circ B)y = \text{tr}((\text{diag } \bar{x})A(\text{diag } y)B^T)$

*proof.* 首先可以发现:  $[(\text{diag } \bar{x})A]_{ij} = \sum_{k=1}^n (\text{diag } \bar{x})_{ik}A_{kj} = \bar{x}_i A_{ij}$ . 同理有:  $[B(\text{diag } y)]_{ij} = B_{ij}y_j$ . 所以:

$$\begin{aligned} \text{tr}((\text{diag } \bar{x})A(\text{diag } y)B^T) &= \sum_{i,j=1}^n [(\text{diag } \bar{x})A]_{ij} [B(\text{diag } y)]_{ij} \\ &= \sum_{i,j=1}^n \bar{x}_i A_{ij} B_{ij} y_j \\ &= \sum_{i,j=1}^n \bar{x}_i (A \circ B)_{ij} y_j \\ &= x^*(A \circ B)y \end{aligned}$$
 □

**Fact 3.** 如果矩阵  $B$  是一个 Hermitian 阵, 则  $B^{1/2}$  存在.

*proof.* 因为  $B$  是一个 Hermitian 阵, 所以存在  $P$ , 使得  $B = P\Lambda P^{-1}$  ( $\Lambda$  是一个对角阵). 这个时候显然,  $B^{1/2} = P\Lambda^{1/2}P^{-1}$ . □

**Fact 4.**  $\text{tr}(ABC) = \text{tr}(BCA)$

*proof.*

$$\text{tr}(ABC) = \sum_i [ABC]_{ii} = \sum_{i,j,k} A_{ij}B_{jk}C_{ki} = \sum_{i,j,k} C_{kj}A_{ij}B_{jk} = \text{tr}(CAB)$$
 □

**Theorem 1** (Schur Product Theorem). 如果  $A, B \in \mathbb{R}^{n \times n}$  都是半正定的, 则  $A \circ B$  也是半正定的.

△ 注:  $A \circ B_{ij} = A_{ij}B_{ij}$

△ 注: 当人们在讨论正定或者半正定的矩阵的时候, 一般都默认这些矩阵是 *Hermitian* 阵 (这个约定可以在 [wiki](#) 上关于正定矩阵的定义发现)

*proof.*

$$\begin{aligned} x^*(A \circ B)x &= \text{tr}((\text{diag } \bar{x})A(\text{diag } x)B^T) \\ &= \text{tr}((\text{diag } \bar{x})A(\text{diag } x)\overline{B}), \quad B \text{ is hermitian} \\ &= \text{tr}(\overline{B}^{1/2}(\text{diag } \bar{x})A(\text{diag } x)\overline{B}^{1/2}) \\ &= \text{tr}(C^*AC), \quad \text{其中 } C = (\text{diag } x)\overline{B}^{1/2} \end{aligned}$$

因为  $A$  半正定, 所以令  $y = Cx$  可得  $y^*Ay \geq 0$ . 这也说明  $C^*AC$  半正定, 所以  $\text{tr}(C^*AC) \geq 0$ . 所以  $x^*(A \circ B)x \geq 0$ , 所以  $A \circ B$  半正定.  $\square$

### 1.1.2 Positive Matrix

下面来学习一些关于 positive matrix 的结果.

**Define 1** (positive matrix). 如果对于一个矩阵  $A$ , 有  $A_{ij} > 0, \forall i, j$ , 则说  $A$  是一个 *positive matrix*.

△ 注: 如果  $A$  是正项矩阵, 记作  $A > 0$ . 如果  $x$  是正项向量, 记作  $x > 0$ .

**Define 2** (谱半径). 矩阵  $A$  的谱半径定义为  $\rho(A) = \max\{|\lambda| : \lambda \text{ 是 } A \text{ 的一个特征值}\}$

**Define 3.** 令  $x$  是一个向量, 则  $|x|$  是一个向量, 且  $|x|_i = |x_i|$ .

△ 注: 这里在复数域  $\mathbb{C}$  上, 所以对于  $a \in \mathbb{C}$ ,  $|a|$  指的是  $a$  的模长.

**Fact 5.** 对于  $\forall x \in \mathbb{C}^n$ , 都  $\exists \theta \in \mathbb{R}$ , 使得  $e^{-i\theta}x = |x|$ .

证明. 这个结论是复数乘法的几何意义的一个应用. 欧拉公式告诉我们, 两个复数相乘, 结果是模长相乘, 夹角相加. 因为所有的复数都能被写成  $re^{i\theta}$  的形式, 其中  $r$  是模长,  $\theta$  是夹角. 所以, 如果我们想知道一个复数  $x$  的模长, 我们可以通过将其旋转到实轴正半轴来实现, 旋转的操作可以有某个单位长度的复数来做到, 具体来说, 如果  $x = re^{i\theta}$ , 我们只需要给他乘上一个  $e^{-i\theta}$  即可.  $\square$

**Fact 6.**  $x \in \mathbb{C}^n, |\sum_i x_i| \leq \sum_i |x_i|$ . 当  $\exists \theta \in \mathbb{R}$ , 使得  $e^{-i\theta}x = |x|$  时取等.

△ 注: 这个式子可以看成绝对值不等式在复数域和高维向量空间的推广.

证明. 首先, 不难发现,  $\sum_i x_i \in \mathbb{C}$ . 所以由上面的结论, 就  $\exists \theta$ , 使得  $e^{-i\theta}(\sum_i x_i) = |\sum_i x_i|$ . 所以

$$\begin{aligned} |\sum_i x_i| &= e^{-i\theta}(\sum_i x_i) \\ &= \operatorname{Re} \left[ e^{-i\theta}(\sum_i x_i) \right] \\ &= \sum_j \operatorname{Re} [e^{-i\theta} x_j] \\ &\leq \sum_j |e^{-i\theta} x_j| \\ &= \sum_j |x_j| \end{aligned}$$

从上面的式子, 不难发现, 这个式子如果要取到等号, 则  $\operatorname{Re} [e^{-i\theta} x_j] = |x_j|, \forall j$ . 这个时候显然就有  $e^{-i\theta} x_j = |x_j|, \forall j$ . 也就是说, 如果要取等号, 则有  $e^{-i\theta} x = |x|$ .  $\square$

**Fact 7.**  $|Ax| \leq |A| |x|$

证明.

$$\begin{aligned} |Ax|_k &= \left| \sum_i A_{ki} x_i \right| \\ &\leq \sum_i |A_{ki} x_i| \\ &= \sum_i |A_{ki}| |x_i| = [|A| |x|]_k \end{aligned}$$

$\square$

**Lemma 1.** 令  $A$  是一个 *positive matrix*.  $\lambda, x$  是  $A$  的一个特征值对, 且  $|\lambda| = \rho(A)$ . 则有  $|x| > 0$  且有  $A|x| = \rho(A)|x|$ , 且  $\exists \theta$  使得  $e^{i\theta} x = |x|$ .

*proof.* 因为  $A > 0$ , 所以直接就有  $z = A|x| > 0$ . 所以

$$z = A|x| = |A||x| \geq |Ax| = |\lambda x| = |\lambda||x| = \rho(A)|x|$$

. 即  $z = A|x| \geq \rho(A)|x|$ . 这个时候不妨设  $y = z - \rho(A)|x| \geq 0$ .

(1) 如果  $y = 0$ , 则  $\rho(A)|x| = A|x| > 0$ , 所以  $\rho(A) > 0, |x| > 0$ .

(2) 如果  $y > 0$ , 则  $Ay = Az - \rho(A)z > 0$ . 所以  $Az > \rho(A)z$ . 这和  $\rho(A)$  的定义矛盾了.

$\triangle$  注:  $\lambda_{\max} = \max_{x \neq 0} \frac{x^* A x}{x^* x}$ , 所以上面 (2) 中的现象会导致  $\frac{z^* A z}{z^* z} > \rho(A)$ , 即  $\lambda_{\max} > \rho(A)$ .

综合 (1), (2) 两点, 有  $A|x| = \rho(A)|x|$ , 且  $\rho(A) > 0, |x| > 0$ . 从  $A|x| = \rho(A)|x|$ , 可以知道

$$\left| \sum_i A_{ki} x_i \right| = \sum_i |A_{ki} x_i|, \quad \forall k$$

这时对于某个固定的  $k$ , 有  $\exists \theta \in \mathbb{R}$ , 使得

$$e^{-i\theta} A_{kj} x_j = |A_{kj}| |x_j|, \quad \forall j$$

因为  $A > 0$ , 所以

$$e^{-i\theta} x_j = |x_j|, \quad \forall j$$

, 即  $e^{-i\theta} x = |x|$ . □

**Lemma 2.**  $A \in \mathbb{R}^{n \times n}, A > 0$ , 则有,  $A$  关于  $\rho(A)$  的几何重数是 1.

*proof.* 设有  $w, z \in \mathbb{C}^n$ , 且有  $\begin{smallmatrix} Aw = \rho(A)w \\ Az = \rho(A)z \end{smallmatrix}$ . 由前面的结论可知:

(1)  $\exists \theta_1 \in \mathbb{R}$  使得  $p = e^{-i\theta_1} z > 0$ , 且  $Ap = \rho(A)p$ .

(2)  $\exists \theta_2 \in \mathbb{R}$  使得  $q = e^{-i\theta_2} w > 0$ , 且  $Aq = \rho(A)q$ .

这个时候, 不妨设  $\beta = \min_{1 \leq i \leq n} \frac{q_i}{p_i}$ ,  $r = q - \beta p$ . 这时  $r \geq 0$  且  $r$  至少有一个地方为 0.

如果  $r \neq 0$ , 则

$$0 < Ar = A(q - \beta p) = \rho(A)q - \beta \rho(A)p = \rho(A)r$$

所以  $\rho(A) > 0, r > 0$ , 这和  $r$  上有一个地方为 0 有矛盾.

若果  $r = 0$ , 则  $q = \beta p$ .

$$\begin{aligned} e^{-i\theta_2} w &= \beta e^{-i\theta_1} z \\ w &= \beta e^{-i(\theta_1 - \theta_2)} z \end{aligned}$$

故  $w$  和  $z$  只呈常数倍关系. □

将上面两个引理的结论收集起来, 就能得到下面定理.

**Theorem 2** (Perron-Frobenius Theorem). 令  $A \in \mathbb{R}^{n \times n}, A > 0$ . 则  $A$  有一个严格为正的 eigenvalue  $\lambda = \rho(A)$ . 且  $\lambda$  对应的特征向量  $x > 0$ .  $A$  关于  $\lambda$  的几何重数是 1.

### 1.1.3 特征值和子空间中的向量

**Fact 8.** 对于一个矩阵  $A$ , 我们可以将他的特征值从小到大排列:

$$\lambda_{\min} = \lambda_1 \leq \lambda_2 \leq \cdots \leq \lambda_{n-1} \leq \lambda_n = \lambda_{\max}$$

**Fact 9.** 对于 Hermitian 矩阵来说, 我们有  $n$  个相互正交的特征向量

**Theorem 3** (Rayleigh theorem). 假设有  $1 \leq i_1 \leq \cdots \leq i_k \leq n$ . 且有  $x_{i_1}, x_{i_2}, \cdots, x_{i_k} \in \mathbb{C}^n$  相互正交. 且有  $Ax_{i_p} = \lambda_{i_p} x_{i_p}, p = 1, 2, \cdots, k$ . 然后令  $S = \text{Span}\{x_{i_1}, x_{i_2}, \cdots, x_{i_k}\}$  则有:

$$\begin{aligned} \lambda_{i_1} &= \min_{\substack{x \neq 0 \\ x \in S}} \frac{x^* Ax}{x^* x} = \min_{\substack{x \in S \\ \|x\|_2=1}} x^* Ax \\ &\leq \max_{\substack{x \in S \\ \|x\|_2=1}} x^* Ax = \max_{\substack{x \neq 0 \\ x \in S}} \frac{x^* Ax}{x^* x} = \lambda_{i_k} \end{aligned}$$

证明. 对于  $\forall x \in S, \|x\|_2 = 1$ , 我们有:

$$x = \alpha_1 x_{i_1} + \alpha_2 x_{i_2} + \cdots + \alpha_k x_{i_k}$$

且

$$\begin{aligned}
x^*x &= 1 \\
1 &= \sum_{j=1}^k (\alpha_j x_{i_j})^* \alpha_j x_{i_j} \\
&= \sum_{j=1}^k \overline{\alpha_j} \alpha_j x_{i_j}^* x_{i_j} \\
&= |\alpha_1|^2 + |\alpha_2|^2 + \cdots + |\alpha_k|^2, \quad \text{这里不妨 } x_{i_j} \text{ 都是单位长度向量}
\end{aligned}$$

又有

$$\begin{aligned}
x^*Ax &= (\alpha_1 x_{i_1} + \cdots + \alpha_k x_{i_k})^* (\alpha_1 \lambda_{i_1} x_{i_1} + \cdots + \alpha_k \lambda_{i_k} x_{i_k}) \\
&= |\alpha_1|^2 \lambda_{i_1} + \cdots + |\alpha_k|^2 \lambda_{i_k}
\end{aligned}$$

因为  $|\alpha_1|^2 + \cdots + |\alpha_k|^2 = 1$ , 所以  $x^*Ax$  是  $\lambda_{i_1}, \cdots, \lambda_{i_k}$  的一个凸组合. 所以, 当然有  $\lambda_{i_1} \leq x^*Ax \leq \lambda_{i_k}$ , 并且刚好可以取到端点.  $\square$

**Lemma 3** (空间交). 令  $S_1, S_2, \cdots, S_k$  是  $V = \mathbb{C}^n$  的子空间.

如  $\delta = \dim S_1 + \dim S_2 + \cdots + \dim S_k - (k-1)n \geq 1$ , 则  $S_1 \cap S_2 \cap \cdots \cap S_k$  中有  $\delta$  个相互正交的单位向量.

证明. 先来考虑两个子空间的情形. 对于任意两个子空间  $S_1, S_2 \subset V$ , 有

$$\dim(S_1 \cap S_2) + \dim(S_1 + S_2) = \dim S_1 + \dim S_2$$

所以

$$\begin{aligned}
\dim(S_1 \cap S_2) &= \dim S_1 + \dim S_2 - \dim(S_1 + S_2) \\
&\geq \dim S_1 + \dim S_2 - \dim V \\
&= \dim S_1 + \dim S_2 - n
\end{aligned}$$

然后, 在这个基础上, 我们来使用归纳法. 假设对于  $k$  个子空间, 有:

$$\dim(S_1 \cap \cdots \cap S_k) = \sum_{i=1}^k \dim S_i - (k-1)n$$

则对于  $k+1$  个子空间的情况, 我们有:

$$\dim(S_{k+1} \cap (S_1 \cap \cdots \cap S_k)) + \dim(S_{k+1} + (S_1 \cap \cdots \cap S_k)) = \dim(S_1 \cap \cdots \cap S_k) + \dim S_{k+1}$$

所以

$$\begin{aligned}
\dim(S_1 \cap \cdots \cap S_{k+1}) &= \sum_{i=1}^k \dim S_i - (k-1)n + \dim S_{k+1} - \dim(S_{k+1} + (S_1 \cap \cdots \cap S_k)) \\
&\leq \sum_{i=1}^{k+1} \dim S_i - (k-1)n - \dim V \\
&= \sum_{i=1}^{k+1} \dim S_i - (k-1)n - n \\
&= \sum_{i=1}^{k+1} \dim S_i - kn
\end{aligned}$$

所以这里有  $\dim(S_1 \cap \cdots \cap S_k) \geq \delta$ . □

**Theorem 4** (Courant-Fischer Theorem).  $A$  是 Hermitian 阵, 则

$$\lambda_k = \min_{\substack{S \subset V \\ \dim S = k}} \max_{\substack{x \neq 0 \\ x \in S}} \frac{x^* A x}{x^* x}$$

*proof.* 由题,  $S$  是任意  $k$  维空间. 令  $S' = \text{Span}\{x_k, \dots, x_n\}$ . 则  $\dim S + \dim S' = k + (n - k + 1) = n + 1$ . 所以  $\delta \geq 1$ , 故  $\{x \neq 0 \wedge x \in S \cap S'\}$  非空. 这时有:

$$\begin{aligned}
\sup_{\substack{x \neq 0 \\ x \in S}} \frac{x^* A x}{x^* x} &\geq \sup_{\substack{x \neq 0 \\ x \in S \cap S'}} \frac{x^* A x}{x^* x} \geq \inf_{\substack{x \neq 0 \\ x \in S \cap S'}} \frac{x^* A x}{x^* x} \\
&\geq \inf_{\substack{x \neq 0 \\ x \in S'}} \frac{x^* A x}{x^* x} \geq \min_{\substack{x \neq 0 \\ x \in S'}} \frac{x^* A x}{x^* x} = \lambda_k
\end{aligned}$$

总结一下就是

$$\sup_{\substack{x \neq 0 \\ x \in S}} \frac{x^* A x}{x^* x} \geq \lambda_k, \quad \forall S \subset \mathbb{C}^n$$

所以自然就有:

$$\inf_{\substack{S \subset \mathbb{C}^n \\ \dim S = k}} \sup_{\substack{x \neq 0 \\ x \in S}} \frac{x^* A x}{x^* x} \geq \lambda_k$$

下面来研究这个等号是否一定能够取到: 令这里的  $x_1, x_2, \dots, x_n$  分别是  $\lambda_1, \dots, \lambda_n$  对应的特征向量, 且相互正交. 所以取  $S = \text{Span}\{x_1, \dots, x_k\}$  即可取到等号, 故

$$\inf_{\substack{S \subset \mathbb{C}^n \\ \dim S = k}} \sup_{\substack{x \neq 0 \\ x \in S}} \frac{x^* A x}{x^* x} = \lambda_k$$

□

#### 1.1.4 柯西交错定理

**Theorem 5** (Weyl Theorem). 将 Hermitian 阵  $A, B, A + B$  的特征值都从小到大排序, 然后我们有:

$$\lambda_i(A + B) \leq \lambda_{i+j}(A) + \lambda_{n-j}(B), \quad \begin{matrix} j \in [0, i-1] \\ i \in [1, n] \end{matrix} \quad (1)$$

对称的, 我们还有:

$$\lambda_{i-j+1}(A) + \lambda_j(B) \leq \lambda_i(A + B), \quad \begin{matrix} j \in [1, i] \\ i \in [1, n] \end{matrix} \quad (2)$$

证明. 这个定理看上去十分复杂, 但是思路很好理解. 先来证明 (1), 设

$$S_1 = \{x_i, \dots, x_n\}, \quad (A+B)x_i = \lambda_i(A+B)x_i.$$

$$S_2 = \{y_1, \dots, y_{i+j}\}, \quad Ay_i = \lambda_i(A)y_i.$$

$$S_3 = \{z_1, \dots, z_{n-j}\}, \quad Bz_i = \lambda_i(B)z_i.$$

很容易发现  $\delta + 2n = \dim S_1 + \dim S_2 + \dim S_3 = (i+j) + (n-j) + (n-i+1) = 2n+1$ . 故  $\delta \geq 1$ , 所以  $S_1 \cap S_2 \cap S_3$  非空, 故对  $x \in S_1 \cap S_2 \cap S_3$ , 有:

$$\begin{aligned} \lambda_i(A+B) \underbrace{\leq}_{S_1} x^*(A+B)x &= x^*Ax + x^*Bx \\ &\leq \underbrace{\lambda_{i+j}(A)}_{S_2} + \underbrace{\lambda_{n-j}(B)}_{S_3} \end{aligned}$$

同理即可证明 (2). □

**Corollary 1.** 令  $A, B$  为 *Hermitian* 阵, 并设  $B$  有  $\pi$  个正特征值,  $\nu$  个负特征值. 则显然有  $\frac{\lambda_{n-\pi}(B)}{\lambda_{\nu+1}(B)} \leq 0$ . 故:

[1]

$$\begin{aligned} \lambda_i(A+B) &\leq \lambda_{i+\pi}(A) + \underbrace{\lambda_{n-\pi}(B)}_{\leq 0} \\ &\leq \lambda_{i+\pi}(A), \quad i \in [1, n-\pi] \end{aligned}$$

[2]

$$\begin{aligned} \lambda_{i-\nu}(A) + \underbrace{\lambda_{1+\nu}(B)}_{\geq 0} &\leq \lambda_i(A+B) \\ \lambda_{i-\nu}(A) &\leq \lambda_i(A+B), \quad i \in [\nu+1, n] \end{aligned}$$

**Fact 10.**  $\forall z \in \mathbb{C}^n$ , 是非 0 向量, 且  $n \geq 2$ , 则有:  $\lambda_{n-1}(zz^*) = 0 = \lambda_2(zz^*)$

*proof.* 考虑两个特征值对,  $\frac{\lambda_1 \neq 0, x \neq 0}{\lambda_2 \neq 0, y \neq 0}$ . 因为  $zz^*x = \lambda_1x$ , 所以  $z^*x \neq 0$ , 同理可得  $z^*y \neq 0$ .

于是就有:

$$\begin{aligned} 0 &\neq (z^*y)^*(z^*x) = y^*zz^*x = \lambda_1y^*x \neq 0 \\ 0 &\neq (z^*x)^*(z^*y) = x^*zz^*y = \lambda_2x^*y \neq 0 \end{aligned}$$

显然,  $(z^*y)^*(z^*x) = \overline{(z^*x)^*(z^*y)}$ , 所以  $\lambda_1y^*x = \overline{\lambda_2x^*y}$  所以  $\lambda_1 = \overline{\lambda_2}$ . 又因为  $zz^*$  是 *Hermitian* 阵, 所以其特征值都是实数, 所以  $\lambda_1 = \lambda_2$ . □

**Fact 11.**  $\forall v \in \mathbb{C}^n$ , 是非 0 向量, 且  $n \geq 2$ , 则有  $vv^*$  的非 0 特征向量  $> 0$ .

*proof.* 设  $\lambda \neq 0, x \neq 0$  为  $vv^*$  的非 0 特征值对. 则,

$$0 < \sum_{i=1}^n |[v^*x]_i|^2 = (v^*x)^*(v^*x) = x^*vv^*x = \lambda x^*x = \lambda \sum_{i=1}^n |x_i|^2$$

. 故  $\lambda > 0$ . □

**Theorem 6** (Cauchy's Interlacing Theorem).  $n \geq 2$ ,  $A$  是 Hermitian 阵, 那么: 对于  $B = A + vv^*$ , 有:

$$\lambda_1(A) \leq \lambda_1(B) \leq \dots \leq \lambda_n(A) \leq \lambda_n(B)$$

*proof.* 因为  $vv^*$  有最多 1 个正特征值, 且其他的特征值都为 0, 所以:

$$\lambda_i(A + vv^*) \leq \lambda_{i+1}(A) + \underbrace{\lambda_{n-1}(vv^*)}_{\leq 0}$$

$$\lambda_i(B) \leq \lambda_{i+1}(A)$$

$$\lambda_{i-1}(A) + \underbrace{\lambda_{i+1}(vv^*)}_{\geq 0} \leq \lambda_i(A + vv^*)$$

$$\lambda_{i-1}(A) \leq \lambda_i(B)$$

□

### 1.1.5 文章中将会用到的一些结论

**Define 4** (为正的特征值个数). 文章中说的特征值个数, 是真的个数, 如果一个矩阵  $A \in \mathbb{R}^{n \times n}$ , 有两个特征值,  $\lambda_1, \lambda_2$ , 这个时候, 是算两个特征值的.

△ 注: 反正最有要保证  $A$  有  $n$  个特征值. *i.e.* 我们对于不平行的特征向量构成的特征值, 我们都算作不同的特征值.

**Fact 12.** 如果  $A \in \mathbb{R}^{n \times n}$  最多只有一个正特征值, 则存在  $B \in \mathbb{R}^{n \times n}, v \in \mathbb{R}^n$ , 使得  $A = B + vv^*$ , 且  $B$  是一个半负定矩阵.

*proof.* 根据 [Courant-Fischer Theorem] 我们知道, 存在一个  $x \in \mathbb{R}^n$ , 使得  $x^*Ax = \lambda_{\max}x^*x$ , 且  $x^*x = 1$ .

这个时候, 我们去找一个  $v \in \mathbb{R}^n$ , 使得  $v^*x = \lambda_{\max}^{1/2}$ . (可以直接取  $v = \lambda_{\max}^{1/2}x$ ) 显然, 这样的  $v$  存在很多个, 我们任意取一个.

这个时候, 令  $B = A - vv^*$ , 就有:

$$\begin{aligned} x^*Bx &= x^*Ax - x^*vv^*x \\ &= \lambda_{\max} - (v^*x)^*(v^*x) \\ &= \lambda_{\max} - \lambda_{\max}^{1/2}\lambda_{\max}^{1/2} \\ &= 0 \end{aligned}$$

因为  $A$  只有一个为正的向量,  $vv^*$  的所有特征向量非负. 所以, 对于  $\forall y \in \mathbb{R}^n$  且  $y$  与  $x$  不平行, 都有  $\frac{y^*Ay}{y^*vv^*y} \leq 0$ , 所以  $y^*By \leq 0$ , 所以  $B$  是半负定矩阵. □

**Define 5** (半定矩阵记法). 文章中, 通常用  $A \preceq 0$  表示  $A$  是负定的. 对称的, 一般用  $A \succeq 0$  表示  $A$  是正定的.

△ 注:  $A \preceq B$  表示  $A - B \preceq 0$ .

**Lemma (2.3).** 令  $A \in \mathbb{R}^{n \times n}$  是一个对称阵. 令  $P \in \mathbb{R}^{m \times n}$ . 如果  $A$  最多有一个正特征值, 则  $PAP^T$  最多有一个正特征值.



*proof.* 由前面的结论知道, 我们可以令  $A = B + vv^*$ , 其中  $B \preceq 0$ . 然后就有:

$$\begin{aligned} PAP^T &= PBP^T + \underbrace{Pvv^*P^T}_{w:=Pv} \\ x^*PAP^Tx &= x^*PBP^Tx + xww^*x \\ &= (P^Tx)^*B(P^Tx) + xww^*x \end{aligned}$$

因为  $B \preceq 0$ , 且  $ww^*$  最多只有一个正特征值, 所以  $PAP^T$  最多只有一个正特征值.  $\square$

**Fact (2.4).** 令  $A \in \mathbb{R}^{n \times k}, B \in \mathbb{R}^{k \times n}$ .  $AB$  的非 0 特征值等于  $BA$  的非 0 特征值. 且具有相同的代数重数.

*proof.*

$$\underbrace{\begin{bmatrix} I_{n \times n} & -A \\ 0 & I_{k \times k} \end{bmatrix}}_{C_1} \underbrace{\begin{bmatrix} AB & 0 \\ B & 0_{k \times k} \end{bmatrix}}_{S_1} \underbrace{\begin{bmatrix} I_{n \times n} & A \\ 0 & I_{k \times k} \end{bmatrix}}_{C_2} = \underbrace{\begin{bmatrix} 0_{n \times n} & 0 \\ B & BA \end{bmatrix}}_{S_2}$$

不难发现,  $C_1C_2 = I$ , 所以  $S_1$  和  $S_2$  相似. 所以  $S_1, S_2$  有相同的特征值.

考虑  $S_1$  的特征方程:

$$\begin{aligned} P(S_1) &= 0 \\ \det(S_1 - \lambda I) &= 0 \\ \det \left( \begin{bmatrix} AB - \lambda I_{n \times n} & 0 \\ B & -\lambda I_{k \times k} \end{bmatrix} \right) &= 0 \end{aligned}$$

计算行列式时, 从右下角按列展开, 不难发现,  $S_1$  的特征值等于  $AB$  的特征值加上  $k$  个 0.

同理可得,  $S_2$  的特征值等于  $BA$  的特征值加上  $n$  个 0.

又因为  $S_1$  和  $S_2$  的特征值相同, 所以不难发现,  $AB$  和  $BA$  的非 0 特征值相同, 且具有相同的代数重数.  $\square$

**Lemma (2.5).**  $A \in \mathbb{R}^{n \times n}$  是一个对称阵, 且最多只有一个正特征值. 那么对任意  $B \in \mathbb{R}^{n \times n}, B \succeq 0$ , 都有  $BA$  最多有一个正特征值.

*proof.* 因为  $B$  半正定, 所以  $B$  实对称. 所以  $\exists P$  使得  $B = P\Lambda P^T$  ( $\Lambda$  为对角阵) 所以

$$\begin{aligned} B &= P\Lambda P^T \\ &= P\Lambda^{1/2}\Lambda^{1/2}P^T \\ &= (\Lambda^{1/2}P^T)^T(\Lambda^{1/2}P^T) \end{aligned}$$

所以,  $B$  可以被写成  $C^TC$  的形式.

故:

$$\begin{aligned} BA &= C^TCA \\ &= C^T(CA) \end{aligned}$$

根据 Fact (2.4) 可以发现,  $C^T(CA)$  和  $CAC^T$  具有相同的非 0 特征值. 又因为  $A$  最多有一个正特征值, 所以  $CAC^T$  最多有一个正特征值, 所以  $BA$  最多有一个正特征值.  $\square$

**Lemma (2.6).** 令  $A \in \mathbb{R}^{n \times n}$  为一个实对称矩阵. 且  $A \geq 0$ ,  $A$  最多有一个正特征值. 然后令  $w \in \mathbb{R}^n$ ,  $w_i = \sum_{j=1}^n A_{ij}$  且  $w_i > 0, \forall i$ . 则

$$A \preceq \frac{ww^T}{\sum_i w_i}$$

*proof.* 令  $W = \text{diag } w$ . 根据 Lemma (2.3)  $\mathcal{A} = W^{-1/2}AW^{-1/2}$  最多只有一个正特征值. (这里  $\mathcal{A}$  成立的原因是  $W$  中的元素都是正数) 然后令  $\sqrt{w} \in \mathbb{R}^n : \sqrt{w}(i) = \sqrt{w_i}$ . 则

$$\begin{aligned} \mathcal{A}\sqrt{w} &= W^{-1/2}AW^{-1/2}\sqrt{w} \\ &= W^{-1/2}A\mathbf{1} \\ &= W^{-1/2}w \\ &= \sqrt{w} \end{aligned}$$

所以  $\sqrt{w}$  取到了  $\mathcal{A}$  唯一的正特征值, i.e. 1.

又有:

$$\sqrt{w}^T (\mathcal{A} - \frac{\sqrt{w}\sqrt{w}^T}{\|\sqrt{w}\|^2})\sqrt{w} = \sqrt{w}^T \mathcal{A}\sqrt{w} - \sqrt{w}^T \sqrt{w} = 0$$

所以  $\mathcal{A} \preceq \frac{\sqrt{w}\sqrt{w}^T}{\|\sqrt{w}\|^2} = \frac{\sqrt{w}\sqrt{w}^T}{\sum_i w_i}$  [这里可以用和 Fact ?? 相同的语句来证明].

更进一步, 因为  $\mathcal{A} \preceq \frac{\sqrt{w}\sqrt{w}^T}{\sum_i w_i}$ , 所以  $\forall x \in \mathbb{R}^n, x^T x = 1$ , 都有:

$$x^T (\mathcal{A} - \frac{\sqrt{w}\sqrt{w}^T}{\sum_i w_i})x \leq 0$$

因为  $W^{1/2}x \in \mathbb{R}^n$ , 故

$$\begin{aligned} (W^{1/2}x)^T (\mathcal{A} - \frac{\sqrt{w}\sqrt{w}^T}{\sum_i w_i})(W^{1/2}x) &\leq 0 \\ x^T W^{1/2} (\mathcal{A} - \frac{\sqrt{w}\sqrt{w}^T}{\sum_i w_i}) W^{1/2} x &\leq 0 \\ x^T (W^{1/2} \mathcal{A} W^{1/2} - \frac{W^{1/2} \sqrt{w} \sqrt{w}^T W^{1/2}}{\sum_i w_i}) W^{1/2} x &\leq 0 \\ x^T (A - \frac{ww^T}{\sum_i w_i}) W^{1/2} x &\leq 0, \quad \forall x \in \mathbb{R}^n \end{aligned}$$

所以

$$A \preceq \frac{ww^T}{\sum_i w_i}$$

□

## 1.2 $d$ -homogeneous multiaffine polynomial

△ 注: 这里的  $d$  不是在说变量的个数, 而是在说次数, 变量的个数一般设为  $n$ .

**Define 6** (log-concave polynomial). 一个多项式  $p(x)$  是 *log-concave* 的, 如果  $\log p(x)$  是 *concave* 的.

$d$ -homogeneous multiaffine polynomial 有一堆性质:

**Fact 13.** 如果  $p(x)$  是  $d$ -homogeneous multiaffine polynomial, 则

$$d \cdot p(x) = \sum_{k=1}^n x_k \partial_k p(x)$$

△ 注: 不难发现, 这里的  $x_k \partial_k p(x)$  相当于将多项式中所有包含  $x_k$  的项相加. 这样将所有变量  $x_k$  枚举完之后, 不难发现,  $p(x)$  中的每一项被加了  $d$  次. 上面的式子还可以写得更加简洁

$$d \cdot p = x^T (\nabla p)$$

**Fact 14.**

$$(d-1) \cdot \nabla p = \sum_{k=1}^n x_k \cdot \nabla (\partial_k p) = \nabla^2 p \cdot x$$

**Fact 15.**

$$(d-2) \cdot \nabla^2 p = \sum_{k=1}^n x_k \cdot \nabla^2 (\partial_k p)$$

△ 注: 要理解上面的等式, 只需注意到  $d$ -homogeneous multiaffine polynomial 求偏导之后, 仍然是  $(d-1)$ -homogeneous multiaffine polynomial.

**Fact 16.**

$$\nabla^2 \log p = \frac{p \cdot \nabla^2 p - (\nabla p)(\nabla p)^T}{p^2}$$

*proof.*

$$\begin{aligned} \partial_i \partial_j p &= \partial_j \left( \frac{\partial_i p}{p} \right) \\ &= \frac{\partial_i \partial_j p \cdot p - \partial_i p \cdot \partial_j p}{p^2} \end{aligned}$$

□

△ 注: 因为  $p$  是 log-concave 的, 所以  $\log p$  是 concave 的, 也就是说

$$\nabla^2 \log p \preceq 0$$

不妨假设  $p$  的所有变量都取正数, 就有:

$$\nabla^2 p \preceq \frac{(\nabla p)(\nabla p)^T}{p}$$

根据我们之前的结论,  $vv^T, \forall v \in \mathbb{R}^n$  最多有一个正特征值, 所以  $\nabla^2 p$  最多有一个正特征值.

### 1.3 Matroid

比较熟悉, 略.

### 1.4 Simplicial Complexes

## 2 正文